


Taller d'Investigació:

Aplicar Mètodes Científics per a Classificar
amb una Introducció al Machine Learning



Coneixes el mètode científic?

- 01 Observació
- 02 Formulació d'hipòtesi
- 03 Experimentació
- 04 Anàlisi de resultats
- 05 Publicar

Fer una pregunta

Hipòtesi

Investigar

Test

Experimentar

Comparar resultats



Com distingir entre tres flors?



D'esquerra a dreta, Iris setosa (per Radomil, CC BY-SA 3.0), Iris versicolor (per Dlanglois, CC BY-SA 3.0) i Iris virginica (per Frank Mayfield, CC BY-SA 2.0).

Font: https://www.tensorflow.org/images/iris_three_species.jpg

- Ús de mesures múltiples en problemes taxonòmics. *Ronald Fischer 1936.*
 - El treball de Ronald Fischer de 1936 tracta sobre com **utilitzar múltiples mesures per tal de classificar organismes en grups**. *Fischer va ser un estadístic britànic que va proposar l'ús de tècniques estadístiques per a entendre millor les similituds i diferències entre els organismes basades en diverses característiques. Això ajuda a millorar la classificació taxonòmica, és a dir, com organitzem i classifiquem els éssers vius en grups.*
- Existeixen diferències entre els petals i sepals !


Observació.

A muscles de gegants!




***Hipòtesi:* diferències estadísticament significatives en les mesures morfològiques entre les tres espècies d'Iris**


Iris setosa



Iris versicolor



Iris virginica



Font: https://superbloov.life/product_details/53265080.html



Experimentació

Es mesuren l'amplada
i longitud del pètal
i el sèpal.



Experimentació: Ús de la tècnica

- Un **algorisme** és una sèrie d'instruccions per a dur a terme una tasca concreta.
- El software lliure **Weka** presenta un entorn amigable per a resoldre problemes de classificació com el present. Està proveït d'una llibreria **d'algorismes classificadors** i permet visualitzar els resultats d'una forma ràpida i ordenada.



Experimentació: Dataset

- Amb l'aplicació Explorer, que incorpora Weka, es carrega un arxiu del tipus .arff amb una sèrie de marques i les dades a analitzar.

```
@RELATION iris

@ATTRIBUTE sepallength REAL
@ATTRIBUTE sepalwidth REAL
@ATTRIBUTE petallength REAL
@ATTRIBUTE petalwidth REAL
@ATTRIBUTE class {Iris-setosa,Iris-versicolor,Iris-virginica}

@DATA
5.1,3.5,1.4,0.2,Iris-setosa
...
7.0,3.2, 1.4,0.2,Iris-versicolor
...
3.2,1.2,0.4,0.3,Iris-virginica
...
```

- Resulta important entendre com estan distribuïdes les dades per a poder aplicar mètodes de classificació a Weka:
- L'etiqueta @relation precedeix al nom que utilitza Weka per a distingir les dades a analitzar. És el títol.
- L'etiqueta @attribute és per als atributs o noms de columnes. Si és una llista, cal situar-la entre claus o si és una dada, cal dir de quin tipus.
- L'etiqueta @data marca l'inici de les dades que serà per files i separats els atributs per comes. Això vol dir que cada instància a classificar està ubicada a una fila.

Experimentació: Weka

- En obrir el menú Explorer s'accedeix a carregar el fitxer. Una vegada carregat és possible eliminar algun paràmetre, Weka els nombra com “Attributes”.

The image shows two screenshots of the Weka software interface. The top screenshot is the 'Weka GUI Chooser' window, which features a menu bar (Program, Visualization, Tools, Help) and a list of applications: Explorer, Experimenter, KnowledgeFlow, Workbench, and Simple CLI. A large red arrow points from the 'Explorer' button to the bottom screenshot. The bottom screenshot is the 'Weka Explorer' window, which has a menu bar (Preprocess, Classify, Cluster, Associate, Select attributes, Visualize) and a toolbar with buttons: Open file..., Open URL..., Open DB..., Generate..., Undo, Edit..., and Save....

Weka Explorer - Filter

Choose: **None** [Apply] [Stop]

Current relation

Relation: iris	Attributes: 5
Instances: 150	Sum of weights: 150

Attributes

[All] [None] [Invert] [Pattern]

No.	Name
1	☒ sepallength
2	☐ sepalwidth
3	☐ petallength
4	☐ petalwidth
5	☐ class

[Remove]

Selected attribute

Statistic	Value
Minimum	4.3
Maximum	7.9
Mean	5.843

Class: class (Nom) [Visualize All]


Status
OK

[Log] [x 0]



Experimentació: Classificador

Amb les dades carregades cal seleccionar el classificador (Classify).



Les opcions de test són:


- **“Use training set”**: Aquesta opció no es pot utilitzar, ja que entrena amb les mateixes mostres que fa el test. Resulta útil per a trobar els millors paràmetres.
- **“Supplied test set”**: Aquesta opció resulta molt adequada. Es reserva a un arxiu **.arff** diferent les instàncies a classificar.
- **“Cross-validation Folds”**: Aquesta opció utilitza una dada “Folds” per a dividir les dades totals en parts. Una part s'utilitza per a test i la resta per a entrenar l'algorisme i així de forma recursiva és possible fer el test a les parts i entrenar amb la resta.
- **“Percentage Split”**: Es defineix un percentatge amb el qual entrenar i amb la resta es fa el test.

Experimentació:

Opcions

Una vegada seleccionat el test és possible obrir un panell amb més opcions.

Cal tenir cura a l'ordre. Si es vol agafar instàncies contigües, cal marcar la selecció de l'opció "Preserve order for % Split"



The image shows a screenshot of the 'Classifier evaluation options' dialog box in Weka. The dialog has a title bar with a close button. It contains several checkboxes and input fields. The 'Output model' checkbox is checked. The 'Output models for training splits' checkbox is unchecked. The 'Output per-class stats' checkbox is checked. The 'Output entropy evaluation measures' checkbox is unchecked. The 'Output confusion matrix' checkbox is checked. The 'Store test data and predictions for visualization' checkbox is checked. The 'Collect predictions for evaluation based on AUROC, etc.' checkbox is checked. The 'Error plot point size proportional to margin' checkbox is unchecked. The 'Output predictions' section has a 'Choose' button and a text field containing 'Null'. The 'Cost-sensitive evaluation' checkbox is unchecked, with a 'Set...' button next to it. The 'Random seed for XVal / % Split' text field contains the value '1'. The 'Preserve order for % Split' checkbox is unchecked. The 'Output source code' checkbox is unchecked, with a text field containing 'WekaClassifier'. At the bottom, there is an 'Evaluation metrics...' button and an 'OK' button.

Classifier evaluation options

- ☒ Output model
- ☐ Output models for training splits
- ☒ Output per-class stats
- ☐ Output entropy evaluation measures
- ☒ Output confusion matrix
- ☒ Store test data and predictions for visualization
- ☒ Collect predictions for evaluation based on AUROC, etc.
- ☐ Error plot point size proportional to margin

Output predictions

☐ Cost-sensitive evaluation

Random seed for XVal / % Split

☐ Preserve order for % Split

☐ Output source code

Classifier output

=== Run information ===

Scheme: weka.classifiers.rules.ZeroR
Relation: iris
Instances: 150
Attributes: 5

sepalwidth
sepalwidth
petalwidth
petalwidth
class

Test mode: 10-fold cross-validation

=== Classifier model (full training set) ===

ZeroR predicts class value: Iris-setosa

Time taken to build model: 0 seconds

=== Stratified cross-validation ===

=== Summary ===

Correctly Classified Instances	50	33.3333 %
Incorrectly Classified Instances	100	66.6667 %
Kappa statistic	0	
Mean absolute error	0.4444	
Root mean squared error	0.4714	
Relative absolute error	100 %	
Root relative squared error	100 %	
Total Number of Instances	150	

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	1,000	1,000	0,333	1,000	0,500	?	0,500	0,333	Iris-setosa
	0,000	0,000	?	0,000	?	?	0,500	0,333	Iris-versicolor
	0,000	0,000	?	0,000	?	?	0,500	0,333	Iris-virginica
Weighted Avg.	0,333	0,333	?	0,333	?	?	0,500	0,333	

=== Confusion Matrix ===

a	b	c	<-- classified as
50	0	0	a = Iris-setosa
50	0	0	b = Iris-versicolor
50	0	0	c = Iris-virginica

Algorisme ZeroR:

Aquest algorisme apareix per defecte quan s'inicia l'Explorador de Weka. S'utilitza per a centrar-se sols amb el "Target" i olvidar-se dels paràmetres predictors. En aquest problema de classificació s'ha forçat l'arxiu .arff amb un nombre igual de classes. Per tant, el resultat d'aplicar aquest serà d'un "Accuracy" del 33%. Es tracta d'un primer pas per a conèixer l'Accuracy a superar pel classificador escollit.

Experimentació:

Algorismes



Exp:Algorismes

Algorisme PART:

Aquest és un algorisme classificador que construeix regles mitjançant un arbre de decisió.

```
Classifier output
Relation: iris
Instances: 150
Attributes: 5
          sepalwidth
          sepalwidth
          petalwidth
          petalwidth
          class
Test mode: 10-fold cross-validation

=== Classifier model (full training set) ===

PART decision list
-----
petalwidth <= 0.6: Iris-setosa (50.0)
petalwidth <= 1.7 AND
petalwidth <= 4.9: Iris-versicolor (48.0/1.0)
: Iris-virginica (52.0/3.0)
Number of Rules :      3

Time taken to build model: 0.03 seconds

=== Stratified cross-validation ===
=== Summary ===

Correctly Classified Instances      141
Incorrectly Classified Instances    9
Kappa statistic                     0.91
Mean absolute error                  0.0482
Root mean squared error              0.1794
Relative absolute error              10.8379 %
Root relative squared error          38.0567 %
Total Number of Instances           150

=== Detailed Accuracy By Class ===

```


	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0,980	0,000	1,000	0,980	0,990	0,985	0,990	0,987	Iris-setosa
	0,940	0,060	0,887	0,940	0,913	0,868	0,954	0,878	Iris-versicolor
	0,900	0,030	0,938	0,900	0,918	0,879	0,959	0,914	Iris-virginica
Weighted Avg.	0,940	0,030	0,941	0,940	0,940	0,911	0,968	0,926	

```

=== Confusion Matrix ===
a b c <-- classified as
49 1 0 | a = Iris-setosa
0 47 3 | b = Iris-versicolor
0 5 45 | c = Iris-virginica
```

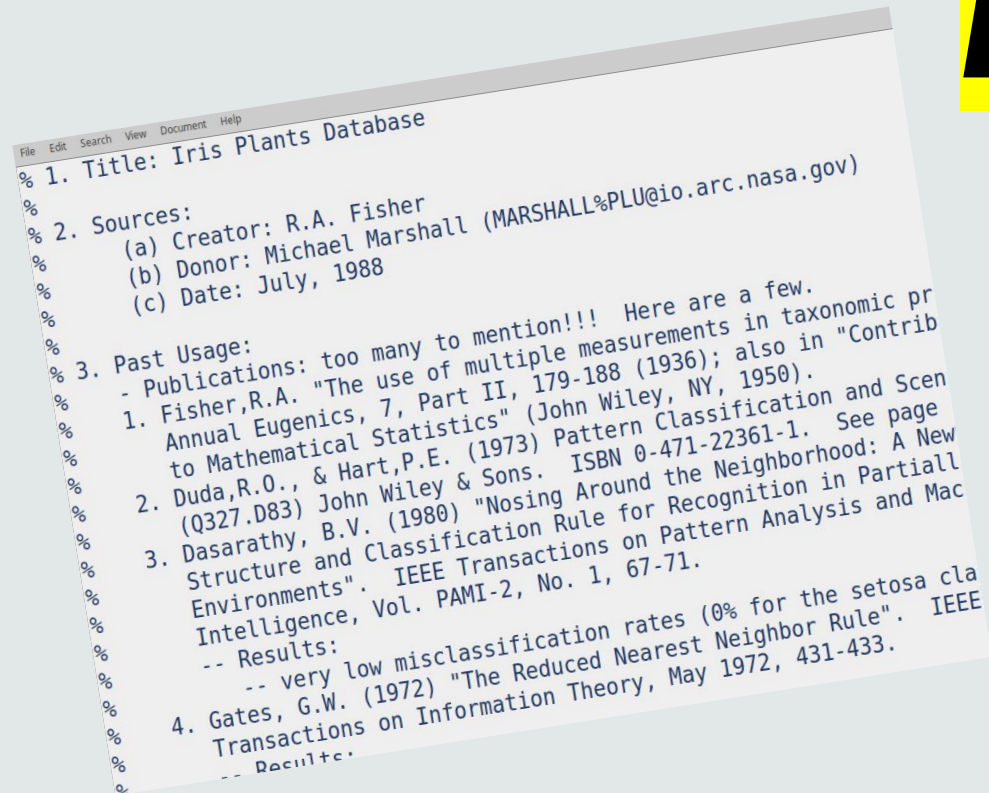
Exp: Visualització de dades

Weka permet visualitzar els diferents paràmetres confrontats.



Experimentació:

Big Data




- Cal recollir un dataset amb moltes dades per a entrenar un algorisme. Això és el que es coneix com **BigData**.
- És possible trobar-ne a internet ja preparats per a Weka. P.e. <https://storm.cis.fordham.edu/~gweiss/data-mining/datasets.html>.
- També es pot crear un sistema de recollida de dades amb mesures de camp, enquestes o mitjançant imatges o sensors.
- Afortunadament Weka incorpora les dades de 50 flors de cada.

Experimentació:

Carregar dataset

- Obrim l'aplicació Weka (Consulta al professor com es fa)
- Inicia l'Explorer i carrega el dataset Iris.arff



Experimentació: Mesura Pètal i Sèpal

- Cal crear un fitxer anomenat irisTest.arff on després de l'etiqueta @DATA introduïm el valor de longitud del sèpal, amplada del sèpal, longitud del pètal, amplada del pètal i la classe que pensem que és separat per comes.

```
@RELATION irisTest

@ATTRIBUTE sepallength REAL
@ATTRIBUTE sepalwidth REAL
@ATTRIBUTE petallength REAL
@ATTRIBUTE petalwidth REAL
@ATTRIBUTE class {Iris-setosa,Iris-versicolor,Iris-virginica}

@DATA
5.1,3.5,1.4,0.2,Iris-setosa
```



Experimentació: Carregar fitxer test

Experimentació: Test

Seleccionar l'algorisme
i executar el test.

```
Classifier output
: Iris-virginica (52.0/3.0)

Number of Rules :      3

Time taken to build model: 0.02 seconds

=== Evaluation on test set ===

Time taken to test model on supplied test set: 0 seconds

=== Summary ===

Correctly Classified Instances      1      100 %
Incorrectly Classified Instances    0      0 %
Kappa statistic                     1
Mean absolute error                  0
Root mean squared error              0
Relative absolute error              0 %
Root relative squared error          0 %
Number of Instances                 1

Detailed Accuracy By Class ===

      TP Rate  FP Rate  Precision  Recall  F-Measure  MCC   ROC Area  PRC Area  Class
      1.000    ?      1.000    1.000    1.000    ?     ?      1.000    Iris-setosa
      ?      0.000    ?      ?      ?      ?     ?      ?      Iris-versicol
      ?      0.000    ?      ?      ?      ?     ?      ?      Iris-virginica
Weighted Avg.  1.000    ?      1.000    1.000    1.000    ?     ?      1.000

=== Confusion Matrix ===

a b c  <-- classified as
1 0 0 | a = Iris-setosa
0 0 0 | b = Iris-versicolor
0 0 0 | c = Iris-virginica
```

Anàlisi de resultats: Matriu de confusió

=== Confusion Matrix ===

a b c <-- classified as

1 0 0 | a = Iris-setosa

0 0 0 | b = Iris-versicolor

0 0 0 | c = Iris-virginica



Publicar els resultats

- <https://ijrpr.com/uploads/V4ISSUE12/IJRPR20661.pdf>
- <https://www.researchgate.net/>
- <https://scholar.google.com/>
- <https://orcid.org/>



Gràcies

Juan Bautista Talens Felis



jb.talensfelis@edu.gva.es



Professor de Sistemes i Aplicacions

